Αυτοσυνεπής Αναλογική Απόσβεση ανά Κόμβο για την Κατάταξη Προσβασιμότητας σε Στοχαστικά Γραφήματα

Ιωάννης Κωνσταντέλλος
Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστήμιο Πατρών

Οκτώβριος 2026

Περίληψη

Οι αλγόριθμοι αποσβεννύμενης διάχυσης (damped diffusions) για την εκτίμηση της αναμενόμενης προσβάσιμης μάζας (reachability / influence spread) $y_i^* = \mathbb{E}[\sum_{v \in C(i)} x_v]$ σε ένα στοχαστικό γράφημα $G = (V, E, p)$ χρησιμοποιούν παραδοσιακά έναν ενιαίο, καθολικό συντελεστή απόσβεσης $\alpha \in (0, 1)$ για όλους τους κόμβους. Ωστόσο, όπως αποδείχθηκε στα πειράματα βελτιστοποίησης (per-node oracle) της προηγούμενης εργασίας μας, η απόδοση διαφορετικού συντελεστή α_i ανά κόμβο προσφέρει σημαντικό επιπλέον κέρδος ακρίβειας κατάταξης ($+0.062$ κατά μέσο όρο και $+0.341$ σε πλέγματα), το οποίο δεν μπορεί να ανακτηθεί μόνο από την τοπική πιθανότητα διαφυγής $P_{\text{esc}}(i)$. Στην παρούσα εργασία εισηγούμαστε την **Αρχή της Αναλογικής Σχετικής Επιρροής**, βάσει της οποίας σε κάθε κόμβο i και σε κάθε επανάληψη t, τόσο η νέα τιμή του y_i όσο και ο τοπικός συντελεστής απόσβεσης α_i καθορίζονται ταυτόχρονα από τη λύση του συζευγμένου συστήματος: $y_i = (1 - \alpha_i)x_i + \alpha_i S_i$ και $\frac{\alpha_i}{1-\alpha_i} = \frac{y_i - x_i}{x_i}$, όπου $S_i = \sum_j w_{ij} y_j$ (για το κλασικό PPR) ή $S_i = P_{\text{esc}}(i) \sum_j w_{ij} y_j$ (για την pull παραλλαγή μας). Επιλύουμε αναλυτικά το μη-γραμμικό αυτό σύστημα σε κλειστή μορφή, αποδεικνύοντας ότι ανάγεται στην παραγοντοποιημένη δευτεροβάθμια εξίσωση $(y_i - x_i)(y_i + x_i - S_i) = 0$, η οποία δίνει τη μη-τετριμμένη λύση $y_i = S_i - x_i$ και $\alpha_i = \frac{S_i - 2x_i}{S_i - x_i}$, καθώς και τη χρονικά υστερημένη (lagged) επαναληπτική μορφή $\alpha_i^{(t+1)} = 1 - \frac{x_i}{y_i^{(t)}}$. Τέλος, τεκμηριώνουμε μαθηματικά γιατί η μέθοδος λειτουργεί βέλτιστα όσο η κατανομή των x προσεγγίζει την ομοιόμορφη κατανομή (κλασικό PageRank) και αναλύουμε τις δύο προτεινόμενες εκδοχές εκτέλεσης: (α) 100% αυτόνομη εκτέλεση και (β) υβριδική εκτέλεση (λ.χ. 50% «τριμμάρισμα / λιμάρισμα») μετά την εκτέλεση ενός βασικού αλγορίθμου.

---

1 Εισαγωγή και Κεντρική Ιδέα

Έστω ένα μη-κατευθυνόμενο στοχαστικό γράφημα $G = (V, E)$ με $|V| = n$ κόμβους, όπου κάθε ακμή $(i, j) \in E$ υπάρχει ανεξάρτητα με πιθανότητα $p_{ij} \in (0, 1]$, και έστω $x \in \mathbb{R}^n_{>0}$ με $\sum_{i=1}^n x_i = 1$ η αρχική (prior) κατανομή σημαντικότητας των κόμβων. Το πρόβλημα της κατάταξης προσβασιμότητας (reachability ranking / single-seed influence spread) [1, 2, 3] συνίσταται στην εκτίμηση της ποσότητας:

$$y_i^* = \mathbb{E}\left[\sum_{v \in C(i)} x_v\right]$$

όπου $C(i)$ είναι η συνδεδεμένη συνιστώσα του κόμβου i σε έναν τυχαίο κόσμο $G' \sim G$.

Στην εργασία μας [4] εξετάσαμε τόσο τον τελεστή του Personalized PageRank (PPR) όσο και την Escape-Scaled Pull παραλλαγή μας με καθολικό συντελεστή $\alpha(\bar{P}_{\text{esc}})$, αποδεικνύοντας παράλληλα ότι η χρήση ξεχωριστού α_i ανά κόμβο κρύβει ένα ανεκμετάλλευτο περιθώριο βελτίωσης ($+0.062$ έως $+0.341$ Spearman ρ).

1.1 Το Φυσικό Σκεπτικό της Προτεινόμενης Ιδέας

Σε κάθε κόμβο i, η συνολική επιρροή y_i αποτελείται από την ενδογενή επιρροή x_i (εντός του ίδιου του κόμβου) και την εξωγενή επιρροή $y_i - x_i$ (εκτός του κόμβου, η οποία προέρχεται από τη διάχυση στο δίκτυο). Η κεντρική ιδέα που προτείνουμε διατυπώνεται ως εξής:

> **Αρχή Αναλογικής Σχετικής Σημαντικότητας:** *Σε κάθε κόμβο και σε κάθε γύρο (iteration), η σχετική σημαντικότητα της επιρροής του κόμβου έξω από τον κόμβο ($y_i - x_i$) ως προς την επιρροή εντός του κόμβου (x_i) πρέπει να είναι ίση με τον λόγο του συντελεστή α_i (που αναζήτησε την επιρροή εκτός του κόμβου) ως προς τον συντελεστή $1 - \alpha_i$ (που την κράτησε στον ίδιο τον κόμβο):*
>
> $$\frac{\alpha_i}{1-\alpha_i} = \frac{y_i - x_i}{x_i}$$

2 Μαθηματική Επίλυση του Συστήματος ως προς y_i και α_i

Για κάθε κόμβο i, συμβολίζουμε με S_i το εισερχόμενο σήμα από τους γείτονές του $j \in N(i)$ στον τρέχοντα γύρο. Ανάλογα με την επιλεγμένη παραλλαγή διάχυσης, το S_i (το οποίο είναι γνωστό στον τρέχοντα γύρο) δίνεται από:

$$S_i \triangleq \begin{cases} \displaystyle\sum_{j \in N(i)} w_{ij} y_j, & \text{(Κλασική παραλλαγή PPR)} \\ P_{\text{esc}}(i) \displaystyle\sum_{j \in N(i)} w_{ij} y_j, & \text{(Escape-Scaled Pull παραλλαγή)} \end{cases}$$

Καλούμαστε να λύσουμε για κάθε κόμβο i το ακόλουθο σύστημα των δύο εξισώσεων με δύο αγνώστους (y_i και α_i), όπου τα $x_i > 0$ και $S_i \geq 0$ είναι γνωστά:

$$\begin{cases} y_i = (1-\alpha_i)x_i + \alpha_i S_i & \text{(Εξίσωση 1: Διάχυση)} \\ \dfrac{\alpha_i}{1-\alpha_i} = \dfrac{y_i - x_i}{x_i} & \text{(Εξίσωση 2: Αναλογία Επιρροής)} \end{cases}$$

2.1 Αναλυτική Αλγεβρική Επίλυση («Η Μαθηματική Λάτζα»)

Βήμα 1ο: Επίλυση της Εξίσωσης 2 ως προς α_i και $1 - \alpha_i$ συναρτήσει του y_i
Από την Εξίσωση 2 έχουμε:

$$\frac{\alpha_i}{1-\alpha_i} = \frac{y_i}{x_i} - 1 \implies \frac{\alpha_i}{1-\alpha_i} + 1 = \frac{y_i}{x_i} \implies \frac{\alpha_i + 1 - \alpha_i}{1-\alpha_i} = \frac{y_i}{x_i} \implies \frac{1}{1-\alpha_i} = \frac{y_i}{x_i}$$

Αντιστρέφοντας τα δύο μέλη (εφόσον $y_i > 0$), βρίσκουμε αμέσως τους συντελεστές $1 - \alpha_i$ και α_i:

$$1 - \alpha_i = \frac{x_i}{y_i} \qquad \text{και} \qquad \alpha_i = 1 - \frac{x_i}{y_i} = \frac{y_i - x_i}{y_i}$$

Βήμα 2ο: Αντικατάσταση στην Εξίσωση 1 και Αναγωγή σε Δευτεροβάθμια Εξίσωση
Αντικαθιστούμε τα $1 - \alpha_i = \frac{x_i}{y_i}$ και $\alpha_i = \frac{y_i - x_i}{y_i}$ στην Εξίσωση 1:

$$y_i = \left(\frac{x_i}{y_i}\right) x_i + \left(\frac{y_i - x_i}{y_i}\right) S_i$$

Πολλαπλασιάζουμε και τα δύο μέλη με $y_i > 0$ για να απαλείψουμε τους παρονομαστές:

$$y_i^2 = x_i^2 + (y_i - x_i) S_i \implies y_i^2 - S_i y_i + x_i S_i - x_i^2 = 0$$

Βήμα 3ο: Ακριβής Παραγοντοποίηση και Εύρεση των Ριζών
Μπορούμε να λύσουμε την παραπάνω δευτεροβάθμια εξίσωση είτε μέσω της διακρίνουσας Δ, είτε με άμεση παραγοντοποίηση!

- **Με παραγοντοποίηση:** Γράφουμε $y_i^2 - x_i^2 = (y_i - x_i)(y_i + x_i)$, οπότε η εξίσωση $y_i^2 - x_i^2 - S_i(y_i - x_i) = 0$ γίνεται:
$$(y_i - x_i)\big(y_i + x_i - S_i\big) = 0$$
- **Με διακρίνουσα:** $\Delta = (-S_i)^2 - 4 \cdot 1 \cdot (x_i S_i - x_i^2) = S_i^2 - 4x_i S_i + 4x_i^2 = (S_i - 2x_i)^2 \geq 0$, άρα:
$$y_i = \frac{S_i \pm (S_i - 2x_i)}{2}$$

Και με τους δύο τρόπους προκύπτουν **δύο ακριβείς, κλειστού τύπου λύσεις**:

1. **Η Τετριμμένη (Απομονωμένη) Λύση:**
$$y_{i,1} = x_i \implies \alpha_{i,1} = \frac{x_i - x_i}{x_i} = 0$$
2. **Η Ενεργή (Μη-Τετριμμένη) Λύση Διάχυσης:**
$$y_i + x_i - S_i = 0 \implies \boxed{y_i = S_i - x_i}$$
και αντικαθιστώντας το $y_i = S_i - x_i$ στον τύπο $\alpha_i = \frac{y_i - x_i}{y_i}$, βρίσκουμε την ακριβή τιμή του α_i:
$$\boxed{\alpha_i = \frac{(S_i - x_i) - x_i}{S_i - x_i} = \frac{S_i - 2x_i}{S_i - x_i} = 1 - \frac{x_i}{S_i - x_i}}$$

2.2 Πότε Ενεργοποιείται η Μη-Τετριμμένη Λύση και οι 3 Τρόποι Υλοποίησης στον Αλγόριθμο

Παρατηρούμε ότι στη μη-τετριμμένη λύση $y_i = S_i - x_i$ και $\alpha_i = \frac{S_i - 2x_i}{S_i - x_i}$, για να είναι το $\alpha_i \in (0, 1)$ (και αντίστοιχα $y_i > x_i$), πρέπει να ισχύει $S_i > 2x_i$. Αυτό μας δίνει τρεις εξαιρετικά καθαρές αλγοριθμικές υλοποιήσεις:

1. **Υλοποίηση Α (Ταυτόχρονη Αλγεβρική Επίλυση στην Ακανονικοποίητη Κλίμακα του y^*):**
Εφόσον η πραγματική προσβάσιμη μάζα $y_i^* = \mathbb{E}[\sum_{v \in C(i)} x_v]$ ικανοποιεί $y_i^* \geq x_i$ (χωρίς κανονικοποίηση σε άθροισμα 1 σε κάθε βήμα, ή με $S_i = P_{\text{esc}}(i) \sum_{j \in N(i)} p_{ij} y_j$), για κάθε κόμβο με $S_i > 2x_i$ εφαρμόζουμε απευθείας:
$$y_i = S_i - x_i, \qquad \alpha_i = \frac{S_i - 2x_i}{S_i - x_i}$$
ενώ αν $S_i \leq 2x_i$, επιλέγεται η άνω περιβάλλουσα $y_i = \max(x_i, S_i - x_i) = x_i$ με $\alpha_i = 0$.
2. **Υλοποίηση Β (Χρονικά Υστερημένη Επανάληψη — Lagged Iteration):**
Αν στον γύρο $t + 1$ το δεξί μέλος της αναλογίας $\frac{\alpha_i^{(t+1)}}{1 - \alpha_i^{(t+1)}} = \frac{y_i^{(t)} - x_i}{x_i}$ υπολογιστεί από την **τρέχουσα εκτίμηση** $y_i^{(t)}$ του προηγούμενου γύρου t (ξεκινώντας από $y_i^{(0)} = x_i + S_i^{(0)} > x_i$), τότε το $\alpha_i^{(t+1)}$ και το νέο $y_i^{(t+1)}$ δίνονται ομαλά για κάθε $S_i^{(t)} > 0$ από τις εξισώσεις:
$$\boxed{\alpha_i^{(t+1)} = \frac{y_i^{(t)} - x_i}{y_i^{(t)}} = 1 - \frac{x_i}{y_i^{(t)}}, \qquad y_i^{(t+1)} = \frac{x_i^2}{y_i^{(t)}} + \left(1 - \frac{x_i}{y_i^{(t)}}\right) S_i^{(t)}}$$

3. **Υλοποίηση Γ (Άμεση Αναλογία Εξωτερικού Σήματος S_i/x_i):**
   Αν η εξωτερική επιρροή στον λόγο μετρηθεί απευθείας από το εισερχόμενο σήμα των γειτόνων $S_i^{(t)}$ ως προς το x_i, δηλαδή $\frac{\alpha_i^{(t+1)}}{1-\alpha_i^{(t+1)}} = \frac{S_i^{(t)}}{x_i}$, τότε προκύπτει η παντού θετική και ομαλή λύση:

$$\boxed{\alpha_i^{(t+1)} = \frac{S_i^{(t)}}{x_i + S_i^{(t)}} \in (0,1), \qquad y_i^{(t+1)} = \frac{x_i^2 + \left(S_i^{(t)}\right)^2}{x_i + S_i^{(t)}}}$$

3 Γιατί η Ομοιόμορφη Κατανομή των x (Κλασικό PageRank) Ευνοεί τον Αλγόριθμο

Η παρατήρηση ότι *όσο περισσότερο η κατανομή των x είναι ομοιόμορφη (δηλαδή κλασικό PageRank με $x_i = \frac{1}{n}$ αντί για Personalized PageRank), τόσο καλύτερα δουλεύει η μέθοδος* επιβεβαιώνεται αυστηρά από τη μαθηματική μορφή της εξίσωσης $\frac{\alpha_i}{1-\alpha_i} = \frac{y_i - x_i}{x_i}$:

1. **Απουσία Απειρισμών (No Division-by-Zero Singularities):** Στο αυστηρό Personalized PageRank (λ.χ. single-seed ή small-seed set), η συντριπτική πλειοψηφία των κόμβων έχει $x_i = 0$ (ή $x_i \approx 0$). Καθώς $x_i \to 0^+$, το κλάσμα $\frac{y_i - x_i}{x_i}$ απειρίζεται ($\to +\infty$), εξωθώντας το $\alpha_i \to 1$ για όλους τους κόμβους εκτός του σπόρου, ανεξάρτητα από την τοπολογία τους!

2. **Κοινή Στάθμη Αναφοράς στο Ομοιόμορφο PageRank ($x_i = \frac{1}{n}$):** Όταν η κατανομή του x είναι ομοιόμορφη ($x_i = \frac{1}{n}$ για κάθε $i \in V$), όλοι οι κόμβοι ξεκινούν από την ίδια ακριβώς ενδογενή βάση $\frac{1}{n}$. Έτσι, ο λόγος:

$$\frac{\alpha_i}{1-\alpha_i} = n y_i - 1 \implies \alpha_i = 1 - \frac{1}{n y_i}$$

   εξαρτάται **αποκλειστικά και καθαρά από την τοπολογική ικανότητα του κόμβου i να συγκεντρώνει μάζα από το γράφημα** (το Edge Percolated Component centrality του!), αποδίδοντας υψηλότερο α_i στους κόμβους του πυρήνα και χαμηλότερο α_i στους απομονωμένους/περιφερειακούς κόμβους.

4 Οι Δύο Εκδοχές Εκτέλεσης: (α) 100% Αυτόνομη vs. (β) 50% «Τριμμάρισμα / Λιμάρισμα»

Σύμφωνα με τον σχεδιασμό μας, ο αλγόριθμος δοκιμάζεται σε δύο διακριτά σχήματα:

4.1 Εκδοχή (α): 100% Αυτόνομη Εκτέλεση (Standalone Execution)

Ο αλγόριθμος ξεκινά εξαρχής από την αρχική κατανομή (με εκκίνηση 1 βήματος $y_i^{(0)} = x_i + S_i^{(0)}$ ώστε $y_i^{(0)} > x_i$) και εκτελεί αποκλειστικά τις εξισώσεις της Ενότητας 2 μέχρις ότου συγκλίνουν ταυτόχρονα τα διανύσματα $y^{(t)}$ και $\alpha^{(t)}$.

4.2 Εκδοχή (β): Υβριδική Εκτέλεση — π.χ. 50% «Τριμμάρισμα / Λιμάρισμα» (Post-Processing Refinement)

Στην εκδοχή αυτή, η αυτοσυνεπής αναλογική απόσβεση χρησιμοποιείται ως τελεστής **«τριμμαρίσματος / λιμαρίσματος» (fine-tuning / polishing)** αφού έχει προηγηθεί ένας άλλος γρήγορος αλγόριθμος:

1. **Φάση 1η (Αρχικός Αλγόριθμος Βάσης):** Εκτελούμε πρώτα τον βαθμονομημένο αλγόριθμο του [4] με καθολικό $\alpha = \text{clip}(0.502 + 0.558\bar{P}_{\text{esc}}, 0.4, 1.0)$ (ή 2 επαναλήψεις Message Passing [5]), παράγοντας το αρχικό διάνυσμα εκτίμησης y^{base} (κανονικοποιημένο στην κλίμακα $y_i^{(0)} = x_i + \gamma y_i^{\text{base}} > x_i$).

2. **Φάση 2η (Τριμμάρισμα / Λιμάρισμα μέσω Αναλογικού α_i):** Εφαρμόζουμε το συζευγμένο σύστημα (y_i, α_i) της Ενότητας 2 πάνω στο $y^{(0)}$ για μικρό αριθμό επαναλήψεων (ή συνδυάζουμε σε ποσοστό $50\% - 50\%$ το αρχικό διάνυσμα y^{base} με το «λιμαρισμένο» διάνυσμα y^{prop}):
$$y^{\text{final}} = 0.50 \cdot \text{normalise}\big(y^{\text{base}}\big) + 0.50 \cdot \text{normalise}\big(y^{\text{prop}}\big)$$

Γιατί η Εκδοχή (β) είναι εξαιρετικά υποσχόμενη: Στη Φάση 1, ο βασικός αλγόριθμος με το καθολικό $\alpha(\bar{P}_{\text{esc}})$ βρίσκει γρήγορα και με απόλυτη ευστάθεια τη μακροσκοπική κλίμακα του y_i σε ολόκληρο το γράφημα (recovered 98.2% του scalar oracle). Στη συνέχεια, στη Φάση 2, η εξίσωση $\frac{\alpha_i}{1-\alpha_i} = \frac{y_i - x_i}{x_i}$ βρίσκει έτοιμο ένα αξιόπιστο y_i για κάθε κόμβο και προσαρμόζει τοπικά το α_i του κάθε κόμβου, «λιμάροντας» τις τοπικές ατέλειες του ενιαίου α και στοχεύοντας απευθείας στο επιπλέον κέρδος ($+0.062$ έως $+0.341$) του per-node oracle!

5 Συμπεράσματα

Η σύζευξη της εξίσωσης διάχυσης με τον αναλογικό κανόνα $\frac{\alpha_i}{1-\alpha_i} = \frac{y_i - x_i}{x_i}$ οδηγεί σε ένα κομψό, πλήρως επιλύσιμο αλγεβρικά σύστημα ($(y_i - x_i)(y_i + x_i - S_i) = 0$ με ενεργή ρίζα $y_i = S_i - x_i$ και $\alpha_i = \frac{S_i - 2x_i}{S_i - x_i}$), το οποίο επιτρέπει σε κάθε κόμβο να ρυθμίζει δυναμικά τον δικό του συντελεστή απόσβεσης α_i σε κάθε γύρο, χωρίς καμία ελεύθερη υπερπαράμετρο.

Αναφορές

[1] D. Kempe, J. Kleinberg, and É. Tardos, "Maximizing the spread of influence through a social network," in *Proc. 9th ACM SIGKDD*, 2003, pp. 137–146.

[2] C.-Y. Lin et al., "Hubba: Hub objects analyzer," *Nucleic Acids Research*, vol. 36, pp. W438–W443, 2008.

[3] C.-H. Chin et al., "cytoHubba: Identifying hub objects and sub-networks from complex interactome," *BMC Systems Biology*, vol. 8, no. Suppl 4, p. S11, 2014.

[4] I. Konstantellos, "Damping from the escape probability: A free calibration rule for diffusion-based reachability ranking in uncertain graphs," CEID, University of Patras, 2026.

[5] B. Karrer, M. E. J. Newman, and L. Zdeborová, "Percolation on sparse networks," *Physical Review Letters*, vol. 113, p. 208702, 2014.